Risque de crédit en Allemagne : repérer les mauvais risques avec des coûts d'erreur asymétriques

Rapport de TP — ENCG Settat, Finance

1. Introduction

Quand une banque accorde un crédit, elle prend un risque : le client peut ne pas rembourser. Elle doit donc décider, dossier par dossier, d'accepter ou de refuser. Cette décision peut s'appuyer sur un modèle statistique qui estime la probabilité qu'un client soit un mauvais risque.

Ce TP traite un cas réel de scoring de crédit avec le jeu de données *Statlog (German Credit Data)*. Le problème a une particularité : les deux erreurs possibles n'ont pas le même coût. Accepter un client qui ne rembourse pas fait perdre une grande partie du capital. Refuser un bon client fait seulement perdre la marge d'intérêts.

La question posée est double :

1. Comment construire un modèle et une règle de décision qui minimisent le coût financier, et non le nombre d'erreurs ?
2. Quels attributs du client et du prêt permettent d'identifier les mauvais risques ?

2. Les données

Le jeu de données vient du dépôt UCI Machine Learning Repository (jeu n° 144). Il a été constitué par le professeur Hans Hofmann, de l'université de Hambourg. Il contient **1 000 dossiers de crédit** décrits par **20 variables** : 7 numériques et 13 catégorielles.

La cible est binaire : **300 dossiers (30 %) sont des mauvais risques** et 700 (70 %) sont des bons risques. Le mauvais risque est la classe positive, car c'est lui que l'on cherche à repérer.

Principales variables :

Type	Variables
Numériques	durée du crédit (mois), montant (DM), mensualité en % du revenu, ancienneté de résidence, âge, nombre de crédits existants, personnes à charge

Type	Variables
Catégorielles	statut du compte courant, historique de crédit, objet du crédit, épargne, ancienneté dans l'emploi, situation personnelle, co-demandeur ou garant, bien possédé, autres plans de crédit, logement, emploi, téléphone, travailleur étranger

Dans le fichier d'origine, les variables catégorielles sont codées par des symboles (A11, A12, etc.). Nous les avons remplacés par leurs libellés pour rendre les graphiques et l'interprétation lisibles.

Le contrôle de qualité est simple : le jeu de données ne contient **aucune valeur manquante**. Il n'y a donc rien à imputer ni à supprimer.

3. Exploration des données

Les statistiques descriptives des variables numériques donnent les ordres de grandeur suivants :

Variable	Moyenne	Minimum	Maximum
Durée (mois)	20,9	4	72
Montant (DM)	3 271	250	18 424
Âge (ans)	35,5	19	75

Quatre constats ressortent de l'exploration :

- **Les classes sont déséquilibrées** (70 % / 30 %). Un modèle qui accepterait tous les dossiers aurait raison 7 fois sur 10, mais accorderait tous les mauvais crédits. L'exactitude (*accuracy*) est donc une mauvaise métrique ici. Nous utilisons une validation stratifiée pour garder les mêmes proportions dans chaque échantillon.
- **Les mauvais risques ont tendance à avoir des crédits plus longs et plus élevés.** Les autres variables numériques, comme les personnes à charge ou l'ancienneté de résidence, séparent très peu les deux classes.
- **Le statut du compte courant est le signal le plus net.** Les clients dont le compte est à découvert sont beaucoup plus souvent de mauvais risques que ceux qui n'ont pas de compte.
- **La durée et le montant sont corrélés.** Un crédit plus élevé est en général plus long. Cette redondance gêne peu un arbre ou une forêt, mais elle justifie de régulariser la régression logistique.

Un point de prudence : l'historique de crédit va dans un sens surprenant. Un compte « critique » est associé à moins de défauts que « tout remboursé ». Les effectifs de certaines modalités sont petits, et les variables sont liées entre elles. Il ne faut donc pas conclure à une relation de cause à effet.

4. Méthodologie

4.1 Type d'apprentissage

Le problème relève de l'**apprentissage supervisé**, plus précisément de la **classification binaire**. Chaque dossier a une étiquette connue (le crédit a-t-il été bien remboursé ou non ?). La cible ne prend que deux valeurs : bon risque (0) ou mauvais risque (1).

Le modèle ne décide pas seul. Il produit une **probabilité** de mauvais risque. Ensuite, un **seuil de décision** transforme cette probabilité en « accepter » ou « refuser ». Séparer ces deux étapes est l'idée centrale du TP : le modèle se juge par l'AUC, la décision se juge par le coût.

4.2 La matrice de coûts

La matrice de coûts est fixée avant la comparaison des modèles, pour ne pas l'ajuster après coup en faveur d'un résultat.

Réalité / Décision	Accepter	Refuser
Bon risque	0	1 (manque à gagner)
Mauvais risque	5 (perte de capital)	0

Le coût de référence est 1 : refuser un bon client, c'est renoncer à la marge d'intérêts. Accepter un mauvais client coûte 5, car la banque perd une part importante du capital prêté. Ce rapport de 5 pour 1 est aussi celui que propose la documentation UCI, ce qui rend les résultats comparables à la littérature. C'est une hypothèse : nous la testons dans la section 7.

4.3 Le seuil théorique

Soit p la probabilité de mauvais risque estimée par le modèle. En refusant, on perd en moyenne (1 − p) × 1. En acceptant, on perd p × 5. Il vaut mieux refuser dès que p × 5 > (1 − p) × 1, c'est-à-dire dès que :

p > t* = c_FP / (c_FP + c_FN) = 1 / 6 ≈ 0,167

Le seuil habituel de 0,5 n'est donc pas adapté. Avec ces coûts, il faut refuser un dossier dès qu'il a **1 chance sur 6** d'être mauvais. Ce seuil théorique n'est exact que si les probabilités du modèle sont bien calibrées.

4.4 Politiques de référence

Deux politiques simples servent de point de comparaison. Sur les 1 000 dossiers, « tout accepter » coûte 5 × 300 = 1 500 et « tout refuser » coûte 1 × 700 = 700. Un modèle n'est utile que s'il fait mieux que « tout refuser ».

4.5 Préparation des données

Le jeu de données est séparé en **750 dossiers d'entraînement et 250 dossiers de test** (découpage stratifié : 30 % de mauvais risques dans chaque partie). Le jeu de test n'est utilisé qu'une seule fois, à la fin.

Le prétraitement est appris sur l'entraînement uniquement, pour éviter toute fuite de données :

- les variables catégorielles sont transformées en colonnes 0/1 (*one-hot encoding*) ;
- les variables numériques sont standardisées (moyenne 0, écart-type 1) ;
- ces étapes sont regroupées dans un `Pipeline`, appliqué de la même façon à l'entraînement, à la validation et au test.

4.6 Modèles comparés

Trois modèles sont comparés, du plus simple au plus complexe :

1. la **régression logistique**, qui sert de référence : simple, rapide, avec des coefficients interprétables ;
2. un **arbre de décision** (profondeur maximale 5, au moins 20 observations par feuille) : des règles « si… alors… » faciles à lire, mais instables ;
3. une **forêt aléatoire** (300 arbres, au moins 3 observations par feuille) : plus précise en général, mais moins lisible.

La comparaison se fait par **validation croisée stratifiée à 5 plis** sur l'entraînement, avec deux mesures :

- l'**AUC**, qui mesure la qualité du classement des dossiers, indépendamment du seuil (0,5 = hasard, 1 = classement parfait) ;
- le **coût total**, calculé à partir de probabilités « hors pli » : chaque dossier est noté par un modèle qui ne l'a jamais vu. On calcule le coût pour tous les seuils et on garde le seuil de coût minimal.

Les modèles sont utilisés sans pondération des classes. C'est le seuil qui prend en charge l'asymétrie des coûts.

5. Résultats

5.1 Validation croisée (750 dossiers d'entraînement)

Modèle	AUC moyenne	Écart-type	Seuil optimal	Coût minimal	Coût à 0,5	Coût à t*
Forêt aléatoire	0,787	0,020	0,230	380	808	418
Régression logistique	0,765	0,036	0,095	398	693	433
Arbre de décision	0,763	0,012	0,070	408	672	411

Sur les 750 dossiers d'entraînement, « tout accepter » coûte 1 125 et « tout refuser » coûte 525.

Ce tableau appelle trois remarques :

- **La forêt aléatoire a la meilleure AUC (0,787)** et le coût minimal le plus faible (380). Elle est retenue. Mais les écarts d'AUC entre les modèles sont du même ordre que les écarts-types : on ne peut pas affirmer avec certitude qu'elle est meilleure que les deux autres.
- **Au seuil de 0,5, les trois modèles coûtent plus cher que « tout refuser »** (808, 693 et 672 contre 525). Utiliser le seuil par défaut ferait donc perdre de l'argent par rapport à une politique triviale.
- **Avec le bon seuil, la forêt coûte 380 contre 525**, soit environ 28 % de moins que la meilleure politique triviale.

La courbe de coût selon le seuil a une forme caractéristique. À gauche (seuil 0), on refuse tout le monde. À droite (seuil 1), on accepte tout le monde. Entre les deux, le coût passe par un minimum, situé loin de 0,5 et assez plat : plusieurs seuils voisins donnent un coût presque identique.

5.2 Évaluation finale sur le jeu de test (250 dossiers)

Le seuil de **0,230** est fixé avant d'ouvrir le jeu de test, à partir des probabilités hors pli de la forêt. Choisir le seuil sur le test reviendrait à l'ajuster sur les données censées l'évaluer.

AUC sur le jeu de test :

Modèle	AUC test
Régression logistique	0,804

Modèle	AUC test
Forêt aléatoire	0,799
Arbre de décision	0,683

Coûts de la forêt aléatoire sur le test (75 mauvais risques, 175 bons risques) :

Règle	Mauvais acceptés (FN)	Bons refusés (FP)	Coût total
Seuil usuel 0,5	47	15	250
Seuil théorique 0,167	4	110	130
Seuil retenu 0,230	**10**	**83**	**133**
Tout accepter	75	0	375
Tout refuser	0	175	175

Lecture des résultats :

- Au seuil retenu, le coût est de **133**, contre 250 au seuil de 0,5 (soit 47 % de moins) et 175 pour « tout refuser » (soit 24 % de moins).
- Le modèle repère **65 des 75 mauvais risques, soit 87 %**. Au seuil de 0,5, il n'en repérait que 28 (37 %).
- Le prix à payer est le refus de **83 bons clients sur 175 (47 %)**. Au seuil de 0,5, seuls 15 étaient refusés (9 %). L'arbitrage est voulu, puisqu'un mauvais risque évité rapporte 5 et un bon client perdu coûte 1. Mais refuser près d'un bon client sur deux est une décision commerciale lourde, que la banque doit assumer.
- Le seuil retenu (coût 133) et le seuil théorique (coût 130) donnent presque le même résultat. Sur ce jeu de données, la formule 1/(1+r) est donc un bon point de départ.

Une nuance : sur le test, la régression logistique obtient une AUC légèrement supérieure à celle de la forêt (0,804 contre 0,799). L'écart est négligeable. Le jeu de test ne compte que 250 dossiers, et son résultat peut changer d'un échantillon à l'autre. L'arbre de décision, lui, chute de 0,763 à 0,683 : il est le plus instable des trois.

6. Application à un nouveau dossier

Le pipeline permet de décider du sort d'un nouveau dossier en appliquant automatiquement le même prétraitement. Exemple avec un dossier fictif : crédit de 6 500 DM sur 36 mois, compte courant à découvert, épargne inférieure à 100 DM.

- Probabilité estimée de mauvais risque : **0,719**.

- Coût espéré si on accepte : 0,719 × 5 = **3,60**.
- Coût espéré si on refuse : 0,281 × 1 = **0,28**.
- Comme 0,719 dépasse largement le seuil de 0,230, la décision est de **refuser**.

7. Analyse de sensibilité aux hypothèses de coût

Le rapport de coûts r = c_FN / c_FP vaut 5 dans notre étude, mais cette valeur est une hypothèse. Une banque réelle aurait des coûts qui varient selon le montant, le type de crédit et la conjoncture. Nous faisons donc varier r de 1 à 20 et nous recalculons le seuil optimal pour la forêt aléatoire.

r	Seuil théorique 1/(1+r)	Seuil optimal (CV)	Plage à ±5 % du coût min	Coût par dossier (seuil adapté)	Coût par dossier (seuil fixé à r = 5)	Regret	Meilleure politique triviale
1	0,500	0,425	0,42 – 0,49	0,240	0,372	0,132	0,300
2	0,333	0,350	0,28 – 0,42	0,360	0,412	0,052	0,600
3	0,250	0,285	0,23 – 0,29	0,444	0,452	0,008	0,700
5	0,167	0,230	0,20 – 0,24	0,532	0,532	0,000	0,700
10	0,091	0,125	0,12 – 0,14	0,620	0,732	0,112	0,700
20	0,048	0,125	0,11 – 0,13	0,700	1,132	0,432	0,700

Trois enseignements :

1. **Le seuil optimal baisse quand r augmente.** Plus un mauvais risque coûte cher, plus la banque doit être exigeante, au prix de refuser davantage de bons clients. Le seuil empirique suit la formule théorique 1/(1+r), mais s'en écarte un peu, car les probabilités d'une forêt ne sont pas parfaitement calibrées.
2. **Le gain du modèle disparaît quand r est très grand.** Pour r = 20, le coût du modèle (0,700) est égal à celui de « tout refuser ». Si un mauvais risque coûte 20 fois plus qu'un bon client perdu, le plus sûr est de refuser presque tout le monde. Pour r = 10, le gain reste faible (0,620 contre 0,700).
3. **Garder le seuil calculé pour r = 5 est risqué si le vrai rapport est très différent.** Le regret est faible pour r entre 2 et 3 (0,052 et 0,008), mais il devient fort pour r = 1 (0,132), r = 10 (0,112) et surtout r = 20 (0,432). Pour r = 1, le seuil fixé à 0,230 fait même pire que « tout accepter » (0,372 contre 0,300).

Le seuil de 0,230 est donc robuste si le vrai rapport de coûts est compris **entre 2 et 5 environ**. En dehors de cette zone, il faut le recalculer.

Le meilleur modèle change-t-il avec les coûts ?

Le classement par AUC ne dépend pas des coûts, mais le classement par coût minimal peut en dépendre. Coût minimal par dossier en validation croisée :

Modèle	r = 1	r = 2	r = 3	r = 5	r = 10	r = 20
Régression logistique	0,248	0,381	0,468	0,531	0,611	0,671
Arbre de décision	0,263	0,360	0,424	0,544	0,649	0,700
Forêt aléatoire	0,235	0,369	0,437	0,507	0,567	0,593

La forêt aléatoire est la meilleure pour r = 1, 5, 10 et 20. L'arbre de décision est meilleur pour r = 2 et 3, mais l'écart avec la forêt est très faible (0,009 pour r = 2). Le choix de la forêt est donc robuste, même si la différence entre modèles reste petite devant l'incertitude d'estimation.

8. Quels attributs signalent un mauvais risque ?

Deux outils complémentaires répondent à cette question.

Les coefficients de la régression logistique indiquent le sens de l'effet de chaque modalité, toutes choses égales par ailleurs. Les cinq modalités les plus associées à un risque élevé sont :

Modalité	Coefficient
Objet du crédit : études	1,02
Bien possédé : inconnu ou aucun	0,71
Épargne inférieure à 100 DM	0,70
Compte courant à découvert (< 0 DM)	0,67
Historique : aucun crédit ou tout remboursé	0,54

L'importance par permutation mélange au hasard les valeurs d'une variable sur le jeu de test et mesure la baisse d'AUC de la forêt. Plus la baisse est forte, plus le modèle s'appuie sur la variable.

Variable	Baisse d'AUC
Statut du compte courant	0,1257
Montant du crédit	0,0168

Variable	Baisse d'AUC
Durée du crédit	0,0166
Historique de crédit	0,0126
Objet du crédit	0,0117

Le **statut du compte courant** domine nettement : sa baisse d'AUC est environ sept fois supérieure à celle de la variable suivante. Viennent ensuite le montant, la durée, l'historique de crédit et l'objet du prêt. L'épargne apparaît comme un signal important dans la régression logistique.

Les deux méthodes convergent donc sur l'idée générale : le **compte courant, l'épargne, l'historique, le montant et la durée** sont les attributs les plus informatifs. L'âge, le logement ou la profession ont un effet plus modeste.

Attention à deux limites :

- Ce sont des **associations, pas des causes**. On ne peut pas dire qu'un changement de statut de compte ferait varier le risque.
- Les importances sont instables quand les variables sont corrélées, comme la durée et le montant.

9. Limites et points d'attention

- **Les coûts sont une hypothèse.** Le rapport de 5 pour 1 vient de la documentation UCI. Dans une vraie banque, il varierait selon le montant du prêt et la conjoncture. C'est la principale limite de l'étude, et c'est pour cela que nous recommandons de communiquer un seuil accompagné d'une plage de rapports de coûts, plutôt qu'une valeur unique.
- **L'échantillon est petit.** Avec 1 000 dossiers, un jeu de test de 250 dossiers et seulement 75 mauvais risques, les résultats varient d'un échantillon à l'autre. C'est pourquoi le seuil est choisi en validation croisée et non sur le test.
- **Les données sont anciennes.** Les montants sont en deutsche marks (DM) et le jeu de données date du siècle dernier. Les résultats ne se transposent pas tels quels au marché actuel, ni au Maroc.
- **Le modèle ignore l'effet du refus.** Les mauvais risques observés viennent de clients à qui la banque avait accordé un crédit. On ne sait rien des clients refusés à l'époque.
- **Équité et cadre juridique.** Le jeu de données contient des variables sensibles : sexe et situation personnelle, âge, statut de travailleur étranger. Un modèle utilisé réellement pour accorder des crédits devrait être examiné du point de vue de l'équité et du droit applicable, ce qui dépasse le cadre de ce TP.

- **Pistes d'amélioration.** On pourrait tester d'autres modèles (gradient boosting), calibrer les probabilités avant de choisir le seuil, et utiliser un coût qui dépend du montant de chaque prêt plutôt qu'un coût fixe.

10. Conclusion

Ce TP montre qu'en scoring de crédit, la qualité d'un modèle ne se résume pas à son exactitude. Six idées sont à retenir :

1. Le problème est un cas d'**apprentissage supervisé, de classification binaire**, avec des **coûts d'erreur asymétriques**.
2. Le travail se fait en **deux étapes** : le modèle estime une probabilité (jugée par l'AUC), puis un seuil la transforme en décision (jugé par le coût).
3. Le **seuil de 0,5 est inadapté**. Le seuil théorique 1/(1+r) vaut environ 0,17 ici, et le seuil retenu est de 0,230.
4. Le **seuil se fixe sans regarder le jeu de test**, à partir de probabilités hors pli.
5. Avec la forêt aléatoire, le coût sur le test est de **133 contre 250 au seuil de 0,5 et 175 pour « tout refuser »**. Le modèle repère 87 % des mauvais risques, au prix de 47 % de bons clients refusés.
6. Le seuil optimal **dépend des hypothèses de coût** : il reste raisonnable pour un rapport r entre 2 et 5 environ, mais doit être recalculé en dehors.

Sur le plan de l'interprétation, le **statut du compte courant** est de loin le premier signal d'alerte, suivi du montant, de la durée, de l'historique de crédit et de l'épargne. Ces résultats décrivent des associations et non des causes.